


**Explore Some New Content about Space!** 



powered by: TEDX



#### IDEA:

TSpaceDx è il nostro impegno per diffondere la cultura spaziale e creare una comunità di persone interessate all'universo.

#### **OBBIETTIVO:**

La nostra missione è ispirare e educare mentre la nostra visione è un mondo dove la conoscenza dello spazio è alla portata di tutti.

## PROBLEMA



Molti trovano difficile accedere a informazioni aggiornate e affidabili sullo spazio.



Esistono poche piattaforme dedicate esclusivamente alla divulgazione scientifica spaziale e ancora meno che permettono la condivisione di esperienze e conoscenze tra appassionati.

### SOLUZIONE



TSpaceDx è la piattaforma ideale per chi vuole esplorare il mondo dello spazio.




Offriamo notizie aggiornate, articoli dettagliati e forum per discussioni.



Con TSpaceDx, gli utenti possono non solo apprendere, ma anche contribuire attivamente alla comunità.

## TECNOLOGIE



### CRITICITA'



Moderare e gestire una comunità online può essere complesso, soprattutto con l'aumento degli utenti.



Minimizzare la latenza e garantire l'alta disponibilità dei servizi è fondamentale per una buona esperienza utente.



Gestire intelligentemente la riproduzione di video dando priorità ai più pertinenti e ricercati.



## TspaceDx



Link git

URL:https://github.com/Merluz/TspacEDx



Link board trello

URL:https://trello.com/b/oiasbz5H



## PySpark Job loadDataSpace

Il codice esegue legge diversi dataset CSV da un bucket S3, li filtra, li unisce e li trasforma utilizzando Spark.

I dataset contengono informazioni su conferenze TEDx, dettagli, immagini e tag. Dopo aver integrato e filtrato i dati il risultato viene scritto in una collezione MongoDB per un utilizzo successivo.



Inizializzazione: Configura il contesto Spark e Glue e avvia il lavoro



Lettura dei dataset: Carica i file CSV da S3 in data frame Spark.



Unione e trasformazione: Integra i dataset unendoli su chiavi comuni e applica filtri per includere solo i dati pertinenti.



Scrittura dei risultati: Salva il dataset finale filtrato in una collezione MongoDB utilizzando AWS Glue.

```
# READ IMAGES DATASET
images_dataset = spark.read \
    .option("header", "true") \
    .option("quote", "\"") \
    .option("escape", "\"") \
    .csv(images_dataset_path) \
    .select(F.col("id").alias("id_ref"),
           F.col("url").alias("image url"))
# JOIN WITH TEDX DATASET
tedx_dataset_main = tedx_dataset_main.join(images_dataset, tedx_dataset_main.id == images_dataset.id_ref, "left") \
    .drop("id ref")
# READ TAGS DATASET AND FILTER FOR "space"
tags_dataset = spark.read.option("header", "true").csv(tags_dataset_path)
tags_dataset_filtered = tags_dataset.filter(F.col("tag") == "space")
# AGGREGATE MODEL, ADD TAGS TO TEDX DATASET
tags_dataset_agg = tags_dataset_filtered.groupBy(F.col("id").alias("id_ref")).agg(F.collect_list("tag").alias("tags"))
# JOIN TAGS WITH TEDY DATASET
tedx_dataset_agg = tedx_dataset_main.join(tags_dataset_agg, tedx_dataset_main.id == tags_dataset_agg.id_ref, "left") \
    .drop("id ref") \
    .select(F.col("id").alias("_id"),
           F.col("slug"),
           F.col("speakers").
           F.col("title").
           F.col("url"),
           F.col("description"),
           F.col("duration"),
           F.col("publishedAt"),
           F.col("image url"),
           F.col("tags"))
# AGGREGATE ALL TAGS FOR EACH TIEM
all_tags_dataset = tags_dataset.groupBy(F.col("id").alias("id_ref")).agg(F.collect_list("tag").alias("all_tags"))
# JOIN ALL TAGS WITH TEDX DATASET
tedx_dataset_agg_final = tedx_dataset_agg.join(all_tags_dataset, tedx_dataset_agg._id == all_tags_dataset.id_ref, "left") \
    .drop("id_ref") \
    .select(F.col(" id"),
           F.col("slug"),
           F.col("speakers"),
           F.col("title"),
           F.col("url"),
           F.col("description"),
           F.col("duration"),
           F.col("publishedAt"),
           F.col("image_url"),
           F.col("all tags").alias("tags"))
```

```
# INIZIALIZZA IL JOB CONTEXT E IL JOB
sc = SparkContext()
glueContext = GlueContext(sc)
spark = glueContext.spark session
job = Job(glueContext)
job.init(args['JOB NAME'], args)
# OPZIONI DI CONNESSIONE MONGODB PER LA LETTURA
read mongo options = {
    "connectionName": "TEDX2024",
    "database": "tspacedx",
    "collection": "tspacedx_data",
    "ssl": "true",
    "ssl.domain match": "false"
# LEGGE T DATT DA MONGODE
tedx dataset = glueContext.create dynamic frame.from options(
    connection type="mongodb",
    connection options=read mongo options
).toDF()
# FUNZIONE PER TROVARE VIDEO CON TAG SIMILI
def find similar videos(df):
    exploded df = df.withColumn("tag", F.explode("tags"))
    # Self-join per trovare tutti i video con almeno un tag in comune diverso da se stessi
   joined df = exploded_df.alias("df1").join(
       exploded df.alias("df2"),
       (F.col("df1.tag") == F.col("df2.tag")) & (F.col("df1. id") != F.col("df2. id")),
    ).select(
       F.col("df1. id").alias("current id"),
       F.col("df2. id").alias("next id")
    ).distinct()
    return joined df
# TROVA I VIDEO SIMILI
similar videos df = find similar videos(tedx dataset)
```

# PySpark Job watch\_next

Questo script in Python utilizza AWS
Glue e Apache Spark per leggere dati da
una collezione MongoDB, identificare
video con tag simili, e determinare i video
suggeriti con priorità basata sul
conteggio delle visualizzazioni successive
e pertinenza dei tag.

I risultati vengono poi scritti in una nuova collezione MongoDB.

# PySpark Job watch\_next



Inizializzazione del Contesto e Job



Lettura dei Dati da MongoDB



Identificazione dei Video

Simili



Lettura dei Dati di

Achievement



Determinazione dei Video

Prioritari



Scrittura dei Risultati in MongoDB

```
# Unisce similar videos df con achievement df per ottenere next video count
joined_df = similar_videos_df.join(
    achievement df,
   similar videos df["next id"] == achievement df[" id"],
 .select(
   similar videos df["current id"],
   similar videos df["next id"],
   achievement_df["next_video_count"]
# Determina il next id con la priorità più alta per ogni current id basato su next video count
window spec = Window.partitionBy("current id").orderBy(F.desc("next video count"))
prioritized df = joined df.withColumn("rank", F.row number().over(window spec)).where(F.col("rank") == 1).drop("rank")
# Scrive prioritized of nella collezione MongoDB watch next data
write mongo options = {
   "connectionName": "TEDX2024",
    "database": "tspacedx",
    "collection": "watch next data",
    "ssl": "true",
    "ssl.domain match": "false"
prioritized dynamic frame = DynamicFrame.fromDF(prioritized df, glueContext, "nested")
glueContext.write_dynamic_frame.from_options(
   frame=prioritized_dynamic_frame,
   connection type="mongodb",
    connection options=write mongo options
```

## mongoDB at as

Esempio di visualizzazione di documento nella collection

## watch\_next\_data

```
_id: ObjectId('667ece882d537247543504c4')
current_id: "489187"
next_id: "507997"

_id: ObjectId('667ece882d537247543504c7')
current_id: "459028"
next_id: "507997"

_id: ObjectId('667ece882d537247543504d8')
current_id: "347139"
next_id: "430928"
```

## tspacedx\_data

```
id: "526916"
 slug: "brian_crim_the_nazis_recruited_to_win_the_cold_war"
 speakers: "Brian Crim"
 title: "The Nazis recruited to win the Cold War"
 url: "https://www.ted.com/talks/brian_crim_the_nazis_recruited_to_win_the_co..."
 description: "In May of 1945 the Third Reich was in chaos. Adolf Hitler was dead and..."
 duration: "385"
 publishedAt: "2024-04-16T15:03:18Z"
 image url: "https://talkstar-assets.s3.amazonaws.com/production/talks/talk 128548/..."

▼ tags : Array (10)
    0: "science"
    1: "engineering"
    2: "rocket science"
    3: "education"
    4: "history"
    5: "war"
    6: "United States"
    7: "space"
    8: "TED-Ed"
```

```
# Carica i dati da MongoDB in un DynamicFrame
tedx_dynamic_frame = glueContext.create_dynamic_frame.from options(
    connection type="mongodb",
    connection options=read mongo options
# Converte DynamicFrame in DataFrame
tedx df = tedx dynamic frame.toDF()
# Estrae i tag e aggiungili come una nuova colonna
tedx df = tedx df.withColumn("tags", F.col("tags"))
# Definisce una lista di tuple tag-valore per accumulare il conteggio
tag value mapping = [
    ("space", 10),
    ("astronomy", 7),
    ("Planets", 7),
   ("aliens", 5),
    ("science", 5),
    ("technology", 5),
    ("future", 7)
# Calcola next video count basato sui tag
tedx df = tedx df.withColumn("next video count",
    sum([F.when(F.array_contains("tags", tag), value).otherwise(0) for tag, value in tag value mapping])
# Seleziona solo le colonne necessarie per achievement df
achievement df = tedx df.select(" id", "next video count") \
    .withColumn("achievement", F.lit("Watched and moved to another video")) \
    .withColumn("date", F.current timestamp())
```

# PySpark Job achievement

Questo script legge i dati da una collezione MongoDB tspacedx\_data e calcola un valore di next\_video\_count per ogni video in base ai tag associati.

Utilizzando una mappatura predefinita di tag e valori, il codice assegna un punteggio a ciascun video. quindi vengono scritti in una collezione MongoDB tspacedx\_achievement.

I valori associati ai tag sono strutturati per essere modificati semplicemente in base alle tendenze.

## mongoDB atlas

### watch\_next\_data

Esempio di visualizzazione di documento nella collection

```
id: "97264"
next video count: 15
achievement: "Watched and moved to another video"
date: 2024-06-29T14:40:53.060+00:00
_id: "483716"
next_video_count: 27
achievement: "Watched and moved to another video"
date: 2024-06-29T14:40:53.060+00:00
_id: "391653"
next video count: 15
achievement: "Watched and moved to another video"
date: 2024-06-29T14:40:53.060+00:00
```

next\_video\_count è il nome della variabile con la priorità del talk

## IMPLEMENTAZIONE JOB



Analizza il trend dei Talk e restituisce il Talk successivo più rilevante sulla base dei tag e delle visualizzazione degli utenti.



Facile modifica valori di rilevanza associati ai tag..



La logica di assegnazione della rilevanza tende ad essere più efficiente con la presenza sostanziosa di utenti attivi.

## CRITICITA'



Generazione dei tag, impossibilità di cercare con parole che non siano tag già presenti.



Possibilità che i Talks più rilevanti restino tali per troppo tempo.



Velocità di caricamento

## TspaceDx



Link git

URL:https://github.com/Merluz/TspacEDx



Link board trello

URL:https://trello.com/b/oiasbz5H



## LAMBDA - watchNext

La funzione watchNext ha il compito, dato il l'id del video corrente, di trovare il talk successivo in base al trend e ottenere tutti i dati relativi a quel talk

#### Chiamata API

```
| Tetty | Raw | Proview | JSON | Tetty | Raw | Proview | Tetty | Raw | Raw
```

```
// Connessione al database
  await connect to db();
  const WatchNextData = mongoose.connection.db.collection('watch next data');
  const TspacedxData = mongoose.connection.db.collection('tspacedx data');
  // Trova il documento con il next id corrispondente al current id fornito
  const watchNextData = await WatchNextData.findOne({ current id });
  if (!watchNextData) {
     return {
          statusCode: 404,
          headers.
         body: JSON.stringify({ message: 'next id non trovato' }),
  const next id = watchNextData.next id;
  // Trova il documento nella collezione tspacedx data con l' id corrispondente al next id
  const tspacedxData = await TspacedxData.findOne({ id: next id });
  if (!tspacedxData) {
      return {
          statusCode: 404,
          headers.
         body: JSON.stringify({ message: 'Documento non trovato' }),
  return
      statusCode: 200,
     headers.
     body: JSON.stringify(tspacedxData),
catch (error)
  return {
      statusCode: 500.
     headers.
      body: JSON.stringify({ message: 'Errore del server', error: error.message }),
```


# LAMBDA - reloadVisualCounter

La funzione reloadVisualCounter ha il compito di incrementare la priorità di ogni tag in base alle visualizzazioni


```
async function updateNextVideoCount( id) {
 try {
   let achievementDoc = await AchievementModel.findOne({    id });
   if (!achievementDoc) {
     achievementDoc = new AchievementModel({ id });
   achievementDoc.next video count += 1;
   // Check if next video count is greater than 99
   if (achievementDoc.next video count > 99 && !achievementDoc.vip) {
      achievementDoc.vip = true;
   await achievementDoc.save();
   catch (error) {
   console.error('Error updating next video count:', error);
   throw error;
```

```
exports.lambda_handler = async (event, context) => {
  try {
    console.log('Received event:', JSON.stringify(event));
    // Connessione a MongoDB prima di eseguire la logica della Lambda
    await connectToDB():
    const id = event[' id'];
    if (! id) {
      throw new Error ('Missing id in event');
    // Aggiorna next video count nel documento MongoDB
    await updateNextVideoCount( id);
    // Recupera il documento aggiornato dal database
    const updatedDoc = await AchievementModel.findOne({ id });
    if (!updatedDoc) {
      throw new Error(`Failed to find document for id: ${ id}`);
    return
     statusCode: 200,
     body: JSON.stringify({ next video count: updatedDoc.next video count })
  } catch (error) {
    console.error('Error processing request:', error);
    return {
     statusCode: 500.
     body: JSON.stringify({ message: `Error processing request: ${error.message}` })
```

## Chiamata API



#### Aumento ad ogni richiamo



next\_video\_count è il nome della variabile con la priorità del talk

## LAMBDA - watchByTag

La funzione watchByTag ha il compito, dato un tag, di trovare i talks associati a quel tag

```
try {
   console.log('Received event:', JSON.stringify(event, null, 2));
   let body = {};
    if (event.body) {
       body = JSON.parse(event.body);
   // Controllo sul tag
    if (!body.tag) {
        return {
            statusCode: 400,
           headers: { 'Content-Type': 'text/plain' },
           body: 'Tag parameter is missing.'
   // Impostazioni predefinite per il numero di documenti per pagina e pagina
   body.doc per_page = body.doc_per_page || 10;
   body.page = body.page | 1;
    // Connessione al database
    await connect to db();
   // Query per trovare i talk con il tag specificato
   const talks = await talk.find({ tags: body.tag })
        .skip((body.doc per page * body.page) - body.doc per page)
        .limit(body.doc per page);
    // Ritorna i risultati
    return {
        statusCode: 200.
        headers: {
            'Content-Type': 'application/json',
            'Access-Control-Allow-Origin': '*', // Permette l'accesso da qualsiasi origine
            'Access-Control-Allow-Methods': 'OPTIONS, POST, GET', // Metodi consentiti
            'Access-Control-Allow-Headers': 'Content-Type', // Header consentiti
        body: JSON.stringify(talks),
```

## CHIAMATA API

```
{
    "tag": "war"
}
```


la risposta della API è una lista di documenti


```
"slug": "brian_crim_the_nazis_recruited_to_win_the_cold_war",
"speakers": "Brian Crim",
"title": "The Nazis recruited to win the Cold War",
"url": "https://www.ted.com/talks/brian_crim_the_nazis_recruited_to_win_the_cold_war",
"description": "In May of 1945 the Third Reich was in chaos. Adolf Hitler was dead and German surrende
   was eager to recruit the smartest minds in Germany before the Soviets got the chance- regardless of
   digs into the clandestine campaign. [Directed by Jeff Le Bars, JetPropulsion.space, narrated by Ac
"duration": "385",
"publishedAt": "2024-04-16T15:03:18Z",
"image_url": "https://talkstar-assets.s3.amazonaws.com/production/talks/talk_128548/0d141979-7ce8-4331
"tags": [
    "science",
    "engineering",
    "rocket science",
    "education",
    "history",
    "war",
    "United States",
    "space",
   "TED-Ed",
    "animation"
"slug": "david_hoffman_sputnik_mania",
"speakers": "David Hoffman",
"title": "Sputnik mania",
"url": "https://www.ted.com/talks/david_hoffman_sputnik_mania",
"description": "Filmmaker David Hoffman shares footage from his feature-length documentary Sputnik Mar
   race and the arms race -- and jump-started science and math education around the world.",
"duration": "210"
```

#### LAMBDA - reloadWatchNext

La funzione reloadWatchNext ha il compito di richiamare il job watch\_next per ricaricare i talks successivi in base alle nuove priorità associate ai talks.

può essere avviata tramite API oppure in automatico ogni quanto di tempo.





```
glueJobName = "watch next"
def lambda handler(event, context):
    try:
        response = client.start job run(JobName=glueJobName)
        logger.info('## STARTED GLUE JOB: ' + glueJobName)
        logger.info('## GLUE JOB RUN ID: ' + response['JobRunId'])
        headers = {
            'Access-Control-Allow-Origin': '*',
            'Access-Control-Allow-Methods': 'OPTIONS, POST, GET',
            'Access-Control-Allow-Headers': 'Content-Type',
        return {
            'statusCode': 200,
            'headers': headers,
            'body': json.dumps('Glue job started successfully')
```

## LAMBDA - reloadDataSpace



La funzione reloadDataSpace ha il compito di richiamare il job loadDataSpace per ricaricare la collezione "tspacedx\_data" dopo ogni volta che viene aggiornato il bucket S3 con nuovi dati.

```
import json
import os
import logging
logger = logging.getLogger()
logger.setLevel(logging.INFO)
import boto3
client = boto3.client('glue')
glueJobName = "loadDataSpace"
def handler(event, context):
    response = client.start job run(JobName = glueJobName)
    logger.info('## STARTED GLUE JOB: ' + glueJobName)
    logger.info('## GLUE JOB RUN ID: ' + response['JobRunId'])
    return response
```

## IMPLEMENTAZIONE JOB



Tempo di esecuzione dei job glue elevato, ricarica dei video prioritari lenta

#### SOLUZIONE:



Sfruttare Amazon S3 Transfer Acceleration per accelerare il trasferimento dei video prioritari in S3. Questo servizio ottimizza automaticamente la velocità di trasferimento utilizzando una rete di distribuzione globale di Amazon CloudFront, riducendo i tempi di latenza e migliorando l'accesso ai dati

## TspaceDx



Link git


URL:https://github.com/Merluz/TspacEDx



Link board trello

URL:https://trello.com/b/oiasbz5H


## Applicazione - GRAFICA



#### **HOMEPAGE**

Appena carica l'applicazione, ci si trova nella homepage, si possono già vedere alcuni video consigliati o caricarne altri tramite il pulsante, oppure navigare nelle altre sezioni






#### **VIDEO-PAGE**

Selezionando uno dei vari video, tramite il pulsante "Guarda", si apre la pagina del video con immagine di anteprima, descrizione del video, lo speaker e il link del video in questione

#### **SEARCH-PAGE**

Se i video caricati non sono quelli di proprio interesse si può cercare tramite "Tag", ad esempio cercando "science" ricercando solo video inerenti. La pagina si raggiunge con I barra di navigazione sottostante





#### **STATISTIC-PAGE**

Nella barra di navigazione sottostante è possibile accedere alla pagina delle statistiche, dove puoi vedere i minuti di riproduzione e la categoria più guardata

#### **VIDEO PLAYER**

In alto, il bottone "help" che porta al video introduttivo su TEDx, con tanto di descrizione. Il video è riproducibile sull'applicazione ed è dotato di controller: pausa/riprendi e pulsanti che ti permettono di andare leggermente più avanti o indietro nel video. Per tornare indietro si usa il bottone "video list"



# Tspa ( ED X

**Explore Some New Content about Space!**